

表 1: 复现结果与论文表 4 的对比 (F1)。每个模型占两行: 第一行为我们复现的分数, 其下为 $\Delta = \text{复现值} - \text{论文值}$ 。平均列按两侧都有的 8/8 列取平均。

模型	VLGuard	JailBreakV	SPA-VL	MMDS-Q	MMDS-R	VLSBench	MM-Safety	BeaverTails-V	平均
Qwen3-VL-8B	0.6003	0.7593	0.6214	0.5532	0.6567	0.3207	0.5005	0.7273	0.5924
Δ vs 论文	+0.0468	-0.1691	-0.0786	-0.0242	+0.2712	-0.4377	-0.1401	+0.0766	-0.0569
Qwen3-VL-4B	0.8238	0.8297	0.6824	0.7485	0.7051	0.8758	0.8820	0.5611	0.7635
Δ vs 论文	+0.2536	-0.0909	+0.0319	+0.2940	+0.2256	+0.1890	+0.2717	-0.1617	+0.1266
LlavaGuard	0.4288	0.4615	0.3047	—	—	0.4556	0.0931	0.3460	0.3483
Δ vs 论文	-0.0715	+0.1425	+0.0592	—	—	-0.2316	-0.1796	-0.2044	-0.1458
SafeGuard-VL	0.6675	0.3806	0.4000	0.3628	0.4153	0.7945	0.5765	0.5052	0.5128
Δ vs 论文	+0.1451	-0.5513	-0.2192	-0.1128	-0.0514	-0.0135	-0.1101	-0.0664	-0.1225
ShieldGemma-2	0.5564	0.3184	0.6499	0.4897	0.1818	0.5359	0.2985	0.5091	0.4425
Δ vs 论文	-0.1403	-0.5833	+0.1455	-0.1545	-0.5039	-0.0926	-0.6671	-0.4063	-0.3003
GuardReasoner-VL-7B	0.8822	0.9005	0.6541	0.4259	0.2914	0.6130	0.6318	0.5149	0.6142
Δ vs 论文	-0.0211	-0.0447	-0.0443	-0.1395	+0.0585	-0.0176	-0.0380	-0.0271	-0.0342
LLaVASHield	0.7816	0.9669	0.6735	0.8667	0.8160	0.9919	0.9974	0.6282	0.8403
Δ vs 论文	-0.1195	-0.0292	+0.0818	-0.1246	-0.1493	-0.0020	+0.0042	-0.0129	-0.0439
SingGuard-2B	0.9549	0.9154	0.6960	0.9379	0.9291	0.9889	0.9530	0.8071	0.8978
Δ vs 论文	+0.0158	-0.0351	-0.0822	-0.0318	+0.0331	+0.0286	+0.1121	+0.0024	+0.0054
SingGuard-4B	0.9472	0.9071	0.7005	0.9032	0.9046	0.9712	0.7891	0.8427	0.8707
Δ vs 论文	+0.0176	-0.0623	-0.0755	-0.0573	+0.0317	+0.0179	-0.0714	+0.0090	-0.0238
SingGuard-8B	0.9536	0.9083	0.7089	0.9571	0.8908	0.9551	0.8653	0.8234	0.8828
Δ vs 论文	+0.0025	-0.0645	-0.0795	-0.0280	-0.0055	-0.0117	-0.0159	-0.0081	-0.0263

说明

- **配置.** 使用官方发布的 checkpoint; SingGuard 各行采用论文 Sec. 2.6 中面向高吞吐基准评测的 `thinking_type=fast`, 贪心解码, `max_model_len=32768`。
- **MMDS 口径.** 语料自带官方 `set` 字段 (train 4045 / val 109 / test 330), 我们与论文一致地评测 `test` 划分。若改为在全量语料上分层采样, SingGuard-8B 会掉到 0.7722/0.7209——该列此前的差距源于我们这边的采样错误, 而非协议或权重的差异。
- **SPA-VL 协议.** 官方测试集为 EvalHarm (265) + EvalHelp (265); 其文件名 *并非* 查询安全性标签 (EvalHelp 衡量有用性, 且包含带仇恨标注的图像; EvalHarm 衡量拒答行为)。我们按 `harm`→`unsafe` / `help`→`safe` 映射, 这是与该列论文数值最自治的读法; 其绝对值应视为依赖协议。
- **JailBreakV 覆盖率.** HF 上仅有约 360 张 (共 28,000 张) 图像, 因此我们采样的 1000 行中有 662 行为纯文本。在带图像子集 (该基准的设计形态) 上, SingGuard-8B 的 F1 为 0.9600, 论文为 0.9728。
- **MM-Safety 全为 unsafe.** 该基准由恶意指令构成 (我们采样的每一行 `gold` 均为 `unsafe`), 因此其 F1 退化为攻击集上的加权召回, 对采样到哪些攻击敏感。
- **基线实现保真度.** 每条基线都走其自身发布的 `prompt`/模板, 而非统一模板。由此发现并修复了两处缺陷: LlavaGuard 的模板以 `chat_template.json` 形式发布且 `tokenizer_config` 中没有内联副本, 导致 vLLM 静默改用通用模板, 26% 的样本返回缺失开头键的 JSON 残片; GuardReasoner-VL 的官方接口 (`INSTRUCTION` 作为 `system message`、`Human user`:/AI assistant: 转录、结论置于 `<result>` 块) 并非常规 `chat` 调用。总体而言基线 `prompt` 仍是近似——论文只公布了 SingGuard 的模板——故其逐列 Δ 仅供参考, 并非精确值。
- **LLaVASHield 的验证价值.** 该模型的发布权重是 LLaVA-NeXT 训练格式 (LlavaQwenForCausalLM, 无 `auto_map`), vLLM 与 transformers 都无法直接加

载；我们做了纯键名重映射的转换（765/765 张量，无 reshape）。转换正确性有一个强判据：MMDS 的评级就是该模型自己生成的（论文 MMDS-Q 0.9913），而我们的 VLSBench 0.9919 / MM-Safety 0.9974 与论文的 0.9939 / 0.9932 几乎一致——错配的权重不可能复现到这个程度。

- **LLaVASHield** 在 MMDS 两列偏低. 0.8667 / 0.8160 vs 论文 0.9913 / 0.9653。原因是上下文而非转换：该 checkpoint 的 `max_position_embeddings` 是 32768，而 MMDS-Q 有 24/330 条提示超出该上限（最长 49255 token）被 vLLM 拒绝、按协议记为错误，且 ** 这些行全是 unsafe 标签 **。precision 为 1.0000（从不误报），缺口集中在召回。
- **LlavaGuard** 的 MMDS 两列记为 N/A。该模型是 LLaVA-1.5 架构，真实上下文只有 4096 token，而 MMDS 的对话（含每图 576 token 的视觉输入）远超这个长度：实际只有 49/330（Q）与 54/327（R）行能被装下，其余被 vLLM 以 400 拒绝。在 15% 覆盖率上算出的 F1（0.0186 / 0.0000）是上下文上限的度量，不是模型判断力的度量，因此留空——论文该列为 0.6800 / 0.6972，说明其评测做了截断或不同的输入组装。
- **Qwen3-VL-235B**. 未跑完：它在 ModelScope 上只有 FP8 版（权重 221.3 GiB）。该模型有 64 个注意力头，tensor-parallel 世界大小必须整除 64——**5 卡不是合法分片数 **，而 4 卡 $\times 48 \text{ GiB} = 192 \text{ GiB}$ 装不下权重，** 唯一可行配置是单节点 8 卡 **。权重已开始在闲置节点上预下载，一旦凑够 8 张空闲卡即自动以 TP=8 启动（logs/qwen235b.log）。
- 评测口径. 全部基线均使用各自发布的 prompt/模板（非统一模板），但仍属近似——论文只公布了 SingGuard 的模板——故基线行的逐列 Δ 供参考。
- **ShieldGemma-2** 是纯图像分类器，无图的行直接跳过，故其 JailBreakV 一行只覆盖有图的 338 条（JailBreakV 公开图像仅 360 张）。