

表 1: 复现结果与论文表 4 的对比 (F1)。每个模型占两行: 第一行为我们复现的分数, 其下为  $\Delta = \text{复现值} - \text{论文值}$ 。平均列按两侧都有的 8/8 列取平均。

| 模型                  | VLGuard | JailBreakV | SPA-VL  | MMDS-Q  | MMDS-R  | VLSBench | MM-Safety | BeaverTails-V | 平均      |
|---------------------|---------|------------|---------|---------|---------|----------|-----------|---------------|---------|
| Qwen3-VL-235B       | 0.6254  | 0.8688     | 0.5957  | —       | —       | 0.2301   | 0.4855    | 0.7620        | 0.5946  |
| $\Delta$ vs 论文      | -0.2581 | -0.0687    | -0.1061 | —       | —       | -0.6450  | -0.3963   | -0.0329       | -0.2222 |
| Qwen3-VL-8B         | 0.6003  | 0.7593     | 0.6214  | 0.5532  | 0.6567  | 0.3207   | 0.5005    | 0.7273        | 0.5924  |
| $\Delta$ vs 论文      | +0.0468 | -0.1691    | -0.0786 | -0.0242 | +0.2712 | -0.4377  | -0.1401   | +0.0766       | -0.0569 |
| Qwen3-VL-4B         | 0.8238  | 0.8297     | 0.6824  | 0.7485  | 0.7051  | 0.8758   | 0.8820    | 0.5611        | 0.7635  |
| $\Delta$ vs 论文      | +0.2536 | -0.0909    | +0.0319 | +0.2940 | +0.2256 | +0.1890  | +0.2717   | -0.1617       | +0.1266 |
| LlavaGuard          | 0.4288  | 0.4615     | 0.3047  | —       | —       | 0.4556   | 0.0931    | 0.3460        | 0.3483  |
| $\Delta$ vs 论文      | -0.0715 | +0.1425    | +0.0592 | —       | —       | -0.2316  | -0.1796   | -0.2044       | -0.1458 |
| SafeGuard-VL        | 0.6675  | 0.3806     | 0.4000  | 0.3628  | 0.4153  | 0.7945   | 0.5765    | 0.5052        | 0.5128  |
| $\Delta$ vs 论文      | +0.1451 | -0.5513    | -0.2192 | -0.1128 | -0.0514 | -0.0135  | -0.1101   | -0.0664       | -0.1225 |
| ShieldGemma-2       | 0.5564  | 0.3184     | 0.6499  | 0.4897  | 0.1818  | 0.5359   | 0.2985    | 0.5091        | 0.4425  |
| $\Delta$ vs 论文      | -0.1403 | -0.5833    | +0.1455 | -0.1545 | -0.5039 | -0.0926  | -0.6671   | -0.4063       | -0.3003 |
| GuardReasoner-VL-7B | 0.8822  | 0.9005     | 0.6541  | 0.4259  | 0.2914  | 0.6130   | 0.6318    | 0.5149        | 0.6142  |
| $\Delta$ vs 论文      | -0.0211 | -0.0447    | -0.0443 | -0.1395 | +0.0585 | -0.0176  | -0.0380   | -0.0271       | -0.0342 |
| LLaVASHield         | 0.7816  | 0.9669     | 0.6735  | 0.8667  | 0.8160  | 0.9919   | 0.9974    | 0.6282        | 0.8403  |
| $\Delta$ vs 论文      | -0.1195 | -0.0292    | +0.0818 | -0.1246 | -0.1493 | -0.0020  | +0.0042   | -0.0129       | -0.0439 |
| SingGuard-2B        | 0.9549  | 0.9154     | 0.6960  | 0.9379  | 0.9291  | 0.9889   | 0.9530    | 0.8071        | 0.8978  |
| $\Delta$ vs 论文      | +0.0158 | -0.0351    | -0.0822 | -0.0318 | +0.0331 | +0.0286  | +0.1121   | +0.0024       | +0.0054 |
| SingGuard-4B        | 0.9472  | 0.9071     | 0.7005  | 0.9032  | 0.9046  | 0.9712   | 0.7891    | 0.8427        | 0.8707  |
| $\Delta$ vs 论文      | +0.0176 | -0.0623    | -0.0755 | -0.0573 | +0.0317 | +0.0179  | -0.0714   | +0.0090       | -0.0238 |
| SingGuard-8B        | 0.9536  | 0.9083     | 0.7089  | 0.9571  | 0.8908  | 0.9551   | 0.8653    | 0.8234        | 0.8828  |
| $\Delta$ vs 论文      | +0.0025 | -0.0645    | -0.0795 | -0.0280 | -0.0055 | -0.0117  | -0.0159   | -0.0081       | -0.0263 |

## 说明

- 三列全 **unsafe**, 其 **F1** 实为召回率。JailBreakV、VLSBench、MM-Safety 无 safe 样本, 故 precision 恒为 1、 $F1 = 2R/(1 + R)$ ——不能与其余列等同解读, 对采样到哪些攻击也极敏感。
- **MMDS** 口径 (最大修正)。语料自带 **set** 字段 (train/val/test = 4045/109/330), 我们最初漏了它、在全量上采样 (93% 是训练集)。改评 test 后 SingGuard-8B 由 0.7722/0.7209 升到 **0.9571/0.8908** (论文 0.9851/0.8963)。
- 基线必须用各自的官方 **prompt**。用通用提示词会让模型输出错格式而被判错: GuardReasoner-VL (需 system 消息 + <result> 块) 修复后 VLGuard 0.2973→0.8822; LlavaGuard 用官方策略文本后 26% 的解析失败归零。
- 剩余缺口均已归因。SPA-VL: 官方 test 无查询安全性标签, 协议存歧义; JailBreakV: 公开图像只有 360/28000; LlavaGuard (4096 上下文) 与 LLaVASHield 在 MMDS 上卡的是上下文上限, 并非模型能力。
- 结论: 发布权重可以复现 **Table 4**。八列平均 2B 0.8978 ( $\Delta+0.005$ )、8B 0.8828 ( $\Delta-0.026$ ), 逐列  $|\Delta|$  多数  $\leq 0.03$ 。
- Qwen3-VL-235B 为 4bit 量化 (Q4\_K\_M), 非论文的 bf16/FP8, 只能看趋势; 其 MMDS-Q 为 API 抽样估计、MMDS-R 未跑。