

表 1: 复现结果与论文表 4 的对比 (F1)。每个模型占两行：第一行为我们复现的分数，其下为 $\Delta = \text{复现值} - \text{论文值}$ 。平均列按两侧都有的 8/8 列取平均。

模型	VLGuard	JailBreakV	SPA-VL	MMDS-Q	MMDS-R	VLSBench	MM-Safety	BeaverTails-V	平均
Qwen3-VL-235B	0.6254	0.8688	0.5957	—	—	0.2301	0.4855	0.7620	0.5946
Δ vs 论文	-0.2581	-0.0687	-0.1061	—	—	-0.6450	-0.3963	-0.0329	-0.2222
Qwen3-VL-8B	0.6003	0.7593	0.6214	0.5532	0.6567	0.3207	0.5005	0.7273	0.5924
Δ vs 论文	+0.0468	-0.1691	-0.0786	-0.0242	+0.2712	-0.4377	-0.1401	+0.0766	-0.0569
Qwen3-VL-4B	0.8238	0.8297	0.6824	0.7485	0.7051	0.8758	0.8820	0.5611	0.7635
Δ vs 论文	+0.2536	-0.0909	+0.0319	+0.2940	+0.2256	+0.1890	+0.2717	-0.1617	+0.1266
LlavaGuard	0.4288	0.4615	0.3047	—	—	0.4556	0.0931	0.3460	0.3483
Δ vs 论文	-0.0715	+0.1425	+0.0592	—	—	-0.2316	-0.1796	-0.2044	-0.1458
SafeGuard-VL	0.6675	0.3806	0.4000	0.3628	0.4153	0.7945	0.5765	0.5052	0.5128
Δ vs 论文	+0.1451	-0.5513	-0.2192	-0.1128	-0.0514	-0.0135	-0.1101	-0.0664	-0.1225
ShieldGemma-2	0.5564	0.3184	0.6499	0.4897	0.1818	0.5359	0.2985	0.5091	0.4425
Δ vs 论文	-0.1403	-0.5833	+0.1455	-0.1545	-0.5039	-0.0926	-0.6671	-0.4063	-0.3003
GuardReasoner-VL-7B	0.8822	0.9005	0.6541	0.4259	0.2914	0.6130	0.6318	0.5149	0.6142
Δ vs 论文	-0.0211	-0.0447	-0.0443	-0.1395	+0.0585	-0.0176	-0.0380	-0.0271	-0.0342
LLaVASHield	0.7816	0.9669	0.6735	0.8667	0.8160	0.9919	0.9974	0.6282	0.8403
Δ vs 论文	-0.1195	-0.0292	+0.0818	-0.1246	-0.1493	-0.0020	+0.0042	-0.0129	-0.0439
SingGuard-2B	0.9549	0.9154	0.6960	0.9379	0.9291	0.9889	0.9530	0.8071	0.8978
Δ vs 论文	+0.0158	-0.0351	-0.0822	-0.0318	+0.0331	+0.0286	+0.1121	+0.0024	+0.0054
SingGuard-4B	0.9472	0.9071	0.7005	0.9032	0.9046	0.9712	0.7891	0.8427	0.8707
Δ vs 论文	+0.0176	-0.0623	-0.0755	-0.0573	+0.0317	+0.0179	-0.0714	+0.0090	-0.0238
SingGuard-8B	0.9536	0.9083	0.7089	0.9571	0.8908	0.9551	0.8653	0.8234	0.8828
Δ vs 论文	+0.0025	-0.0645	-0.0795	-0.0280	-0.0055	-0.0117	-0.0159	-0.0081	-0.0263

说明

- 基准分组 (原文 Table 4 说明) . 视觉语言越狱 (JailBreakV、VLSBench、MM-Safety)、政策驱动的多模态审核 (VLGuard、SPA-VL、BeaverTails-V)、MMDS 的查询/响应拆分 (MMDS-Q 判用户侧意图、MMDS-R 判助手侧协助, 两者独立评分)。
- 评测协议 (原文 4.1) . 全部基准走同一生成式 guard 接口; 解析首个 safe/unsafe 判定 token, 需归因时取 <answer> 内的类别; 无法给出判定的输出 按错误误计、不重试。query-side 判请求本身是否应拦截, response-side 判回复是否构成有害协助, 多模态 response 基准按 (query, image, response) 三元组联合判定。
- 三列越狱类基准 (原文 4.2 的提醒) . 原文指出这三列” 会被专门训练于越狱模板的 guard 刷至饱和, 单一聚合数值可能掩盖对拒绝模板的过拟合”。本表中 JailBreakV、VLSBench、MM-Safety 采样到的每一行 gold 均为 unsafe, 故 precision 恒为 1、 $F1 = 2R/(1 + R)$ ——其数值只反映召回。
- MMDS 口径. 语料自带 set 字段 (train/val/test = 4045/109/330), 与原文一致评测 test 划分。八列宏平均: SingGuard-2B 0.8978、4B 0.8707、8B 0.8828 (原文 0.8924 / 0.8945 / 0.9092)。
- 其余各列差异的来源. SPA-VL: 官方 test 集为 EvalHarm + EvalHelp, 本身不含查询安全性标签, 映射依赖协议选择; JailBreakV: 公开图像仅 360/28000, 我们 1000 条中 662 条为纯文本; LlavaGuard 与 LLaVASHield 在 MMDS 上受各自上下文上限 (4096 / 32768) 限制, 超出部分按协议记为错误。
- 基线提示词. 原文仅公布 SingGuard 的模板, 基线提示词依其各自模型卡组装, 故基线行的逐列 Δ 为参考值。

- Qwen3-VL-235B 为 4bit 量化 (Q4_K_M), 非原文的 bf16/FP8, 仅供趋势参考; 其 MMDS-Q 为 API 抽样估计、MMDS-R 未跑。