

表 1: 复现结果与论文表 4 的对比 (F1)。每个模型占两行：第一行为我们复现的分数，其下为 $\Delta = \text{复现值} - \text{论文值}$ 。平均列按两侧都有的 8/8 列取平均。

模型	VLGuard	JailBreakV	SPA-VL	MMDS-Q	MMDS-R	VLSBench	MM-Safety	BeaverTails-V	平均
Qwen3-VL-235B	0.6254	0.8688	0.5957	—	—	0.2301	0.4855	0.7620	0.5946
Δ vs 论文	-0.2581	-0.0687	-0.1061	—	—	-0.6450	-0.3963	-0.0329	-0.2222
Qwen3-VL-8B	0.6003	0.7593	0.6214	0.5532	0.6567	0.3207	0.5005	0.7273	0.5924
Δ vs 论文	+0.0468	-0.1691	-0.0786	-0.0242	+0.2712	-0.4377	-0.1401	+0.0766	-0.0569
Qwen3-VL-4B	0.8238	0.8297	0.6824	0.7485	0.7051	0.8758	0.8820	0.5611	0.7635
Δ vs 论文	+0.2536	-0.0909	+0.0319	+0.2940	+0.2256	+0.1890	+0.2717	-0.1617	+0.1266
LlavaGuard	0.4288	0.4615	0.3047	—	—	0.4556	0.0931	0.3460	0.3483
Δ vs 论文	-0.0715	+0.1425	+0.0592	—	—	-0.2316	-0.1796	-0.2044	-0.1458
SafeGuard-VL	0.6675	0.3806	0.4000	0.3628	0.4153	0.7945	0.5765	0.5052	0.5128
Δ vs 论文	+0.1451	-0.5513	-0.2192	-0.1128	-0.0514	-0.0135	-0.1101	-0.0664	-0.1225
ShieldGemma-2	0.5564	0.3184	0.6499	0.4897	0.1818	0.5359	0.2985	0.5091	0.4425
Δ vs 论文	-0.1403	-0.5833	+0.1455	-0.1545	-0.5039	-0.0926	-0.6671	-0.4063	-0.3003
GuardReasoner-VL-7B	0.8822	0.9005	0.6541	0.4259	0.2914	0.6130	0.6318	0.5149	0.6142
Δ vs 论文	-0.0211	-0.0447	-0.0443	-0.1395	+0.0585	-0.0176	-0.0380	-0.0271	-0.0342
LLaVaShield	0.7816	0.9669	0.6735	0.8667	0.8160	0.9919	0.9974	0.6282	0.8403
Δ vs 论文	-0.1195	-0.0292	+0.0818	-0.1246	-0.1493	-0.0020	+0.0042	-0.0129	-0.0439
SingGuard-2B	0.9549	0.9154	0.6960	0.9379	0.9291	0.9889	0.9530	0.8071	0.8978
Δ vs 论文	+0.0158	-0.0351	-0.0822	-0.0318	+0.0331	+0.0286	+0.1121	+0.0024	+0.0054
SingGuard-4B	0.9472	0.9071	0.7005	0.9032	0.9046	0.9712	0.7891	0.8427	0.8707
Δ vs 论文	+0.0176	-0.0623	-0.0755	-0.0573	+0.0317	+0.0179	-0.0714	+0.0090	-0.0238
SingGuard-8B	0.9536	0.9083	0.7089	0.9571	0.8908	0.9551	0.8653	0.8234	0.8828
Δ vs 论文	+0.0025	-0.0645	-0.0795	-0.0280	-0.0055	-0.0117	-0.0159	-0.0081	-0.0263

说明

本表只列出两类内容：原文未作规定、由我们选定的口径；以及原文自己指出有问题的部分。原文已经写明的评测协议与基准分组不再重复。

- 三列越狱类基准的读法。原文已提醒这三列”会被专门训练于越狱模板的 guard 刷至饱和”。在我们的采样中，JailBreakV、VLSBench、MM-Safety 的每一行 gold 都是 unsafe，于是 precision 恒为 1、 $F1 = 2R/(1 + R)$ ——这三列只反映召回，不能与其余列等同看待。
- MMDS 的划分。语料自带 set 字段 (train/val/test = 4045/109/330)，我们取 test 划分。
- SPA-VL 的标签映射。官方 test 集为 EvalHarm 与 EvalHelp，其文件名不含查询安全性标签；我们按 harm→unsafe、help→safe 映射。
- JailBreakV 的输入形态。公开图像只有 360/28000 张，我们采样的 1000 条中有 662 条为纯文本。
- MMDS 上两个模型的上下文边界。LlavaGuard (4096) 与 LLaVaShield (32768) 各有部分样本超出自身上下文上限，按协议记为错误；LlavaGuard 的 MMDS 两列因此覆盖率不足，留空。
- 基线提示词。原文只公布了 SingGuard 的模板，基线按其各自模型卡组装，故基线行的 Δ 为参考值。
- Qwen3-VL-235B 的限定。本地六列使用 4bit 量化 (Q4_K_M)；MMDS-Q 为 API 抽样估计、MMDS-R 未运行。该行仅供趋势参考。