

表 1: 复现结果与论文表 4 的对比 (F1)。每个模型占两行：第一行为我们复现的分数，其下为  $\Delta = \text{复现值} - \text{论文值}$ 。平均列按两侧都有的 8/8 列取平均。

| 模型                  | VLGuard | JailBreakV | SPA-VL  | MMDS-Q  | MMDS-R  | VLSBench | MM-Safety | BeaverTails-V | 平均      |
|---------------------|---------|------------|---------|---------|---------|----------|-----------|---------------|---------|
| Qwen3-VL-8B         | 0.6003  | 0.7593     | 0.6214  | 0.5532  | 0.6567  | 0.3207   | 0.5005    | 0.7273        | 0.5924  |
| $\Delta$ vs 论文      | +0.0468 | -0.1691    | -0.0786 | -0.0242 | +0.2712 | -0.4377  | -0.1401   | +0.0766       | -0.0569 |
| Qwen3-VL-4B         | 0.8238  | 0.8297     | 0.6824  | 0.7485  | 0.7051  | 0.8758   | 0.8820    | 0.5611        | 0.7635  |
| $\Delta$ vs 论文      | +0.2536 | -0.0909    | +0.0319 | +0.2940 | +0.2256 | +0.1890  | +0.2717   | -0.1617       | +0.1266 |
| LlavaGuard          | 0.4288  | 0.4615     | 0.3047  | —       | —       | 0.4556   | 0.0931    | 0.3460        | 0.3483  |
| $\Delta$ vs 论文      | -0.0715 | +0.1425    | +0.0592 | —       | —       | -0.2316  | -0.1796   | -0.2044       | -0.1458 |
| SafeGuard-VL        | 0.6675  | 0.3806     | 0.4000  | 0.3628  | 0.4153  | 0.7945   | 0.5765    | 0.5052        | 0.5128  |
| $\Delta$ vs 论文      | +0.1451 | -0.5513    | -0.2192 | -0.1128 | -0.0514 | -0.0135  | -0.1101   | -0.0664       | -0.1225 |
| ShieldGemma-2       | 0.5564  | 0.3184     | 0.6499  | 0.4897  | 0.1818  | 0.5359   | 0.2985    | 0.5091        | 0.4425  |
| $\Delta$ vs 论文      | -0.1403 | -0.5833    | +0.1455 | -0.1545 | -0.5039 | -0.0926  | -0.6671   | -0.4063       | -0.3003 |
| GuardReasoner-VL-7B | 0.8822  | 0.9005     | 0.6541  | 0.4259  | 0.2914  | 0.6130   | 0.6318    | 0.5149        | 0.6142  |
| $\Delta$ vs 论文      | -0.0211 | -0.0447    | -0.0443 | -0.1395 | +0.0585 | -0.0176  | -0.0380   | -0.0271       | -0.0342 |
| LLaVASHield         | 0.7816  | 0.9669     | 0.6735  | 0.8667  | 0.8160  | 0.9919   | 0.9974    | 0.6282        | 0.8403  |
| $\Delta$ vs 论文      | -0.1195 | -0.0292    | +0.0818 | -0.1246 | -0.1493 | -0.0020  | +0.0042   | -0.0129       | -0.0439 |
| SingGuard-2B        | 0.9549  | 0.9154     | 0.6960  | 0.9379  | 0.9291  | 0.9889   | 0.9530    | 0.8071        | 0.8978  |
| $\Delta$ vs 论文      | +0.0158 | -0.0351    | -0.0822 | -0.0318 | +0.0331 | +0.0286  | +0.1121   | +0.0024       | +0.0054 |
| SingGuard-4B        | 0.9472  | 0.9071     | 0.7005  | 0.9032  | 0.9046  | 0.9712   | 0.7891    | 0.8427        | 0.8707  |
| $\Delta$ vs 论文      | +0.0176 | -0.0623    | -0.0755 | -0.0573 | +0.0317 | +0.0179  | -0.0714   | +0.0090       | -0.0238 |
| SingGuard-8B        | 0.9536  | 0.9083     | 0.7089  | 0.9571  | 0.8908  | 0.9551   | 0.8653    | 0.8234        | 0.8828  |
| $\Delta$ vs 论文      | +0.0025 | -0.0645    | -0.0795 | -0.0280 | -0.0055 | -0.0117  | -0.0159   | -0.0081       | -0.0263 |

## 说明

- **配置.** 使用官方发布的 checkpoint；SingGuard 各行采用论文 Sec. 2.6 中面向高吞吐基准评测的 `thinking_type=fast`，贪心解码，`max_model_len=32768`。
- **MMDS 口径.** 语料自带官方 `set` 字段 (train 4045 / val 109 / test 330)，我们与论文一致地评测 `test` 划分。若改为在全量语料上分层采样，SingGuard-8B 会掉到 0.7722/0.7209——该列此前的差距源于我们这边的采样错误，而非协议或权重的差异。
- **SPA-VL 协议.** 官方测试集为 EvalHarm (265) + EvalHelp (265)；其文件名 *并非* 查询安全性标签 (EvalHelp 衡量有用性，且包含带仇恨标注的图像；EvalHarm 衡量拒答行为)。我们按 `harm`→`unsafe` / `help`→`safe` 映射，这是与该列论文数值最自治的读法；其绝对值应视为依赖协议。
- **JailBreakV 覆盖率.** HF 上仅有约 360 张 (共 28,000 张) 图像，因此我们采样的 1000 行中有 662 行为纯文本。在带图像子集 (该基准的设计形态) 上，SingGuard-8B 的 F1 为 0.9600，论文为 0.9728。
- **MM-Safety 全为 unsafe.** 该基准由恶意指令构成 (我们采样的每一行 `gold` 均为 `unsafe`)，因此其 F1 退化为攻击集上的加权召回，对采样到哪些攻击敏感。
- **基线实现保真度.** 每条基线都走其自身发布的 `prompt`/模板，而非统一模板。由此发现并修复了两处缺陷：LlavaGuard 的模板以 `chat_template.json` 形式发布且 `tokenizer_config` 中没有内联副本，导致 vLLM 静默改用通用模板，26% 的样本返回缺失开头键的 JSON 残片；GuardReasoner-VL 的官方接口 (INSTRUCTION 作为 `system message`、`Human user`:/AI assistant: 转录、结论置于 `<result>` 块) 并非常规 `chat` 调用。总体而言基线 `prompt` 仍是近似——论文只公布了 SingGuard 的模板——故其逐列  $\Delta$  仅供参考，并非精确值。
- **LLaVASHield 的验证价值.** 该模型的发布权重是 LLaVA-NeXT 训练格式 (LlavaQwenForCausalLM, 无 `auto_map`)，vLLM 与 `transformers` 都无法直接加

载；我们做了纯键名重映射的转换（765/765 张量，无 reshape）。转换正确性有一个强判据：MMDS 的评级就是该模型自己生成的（论文 MMDS-Q 0.9913），而我们的 VLSBench 0.9919 / MM-Safety 0.9974 与论文的 0.9939 / 0.9932 几乎一致——错配的权重不可能复现到这个程度。

- **LLaVASHield** 在 MMDS 两列偏低. 0.8667 / 0.8160 vs 论文 0.9913 / 0.9653。原因是上下文而非转换：该 checkpoint 的 `max_position_embeddings` 是 32768，而 MMDS-Q 有 24/330 条提示超出该上限（最长 49255 token）被 vLLM 拒绝、按协议记为错误，且 \*\* 这些行全是 unsafe 标签 \*\*。precision 为 1.0000（从不误报），缺口集中在召回。
- **LlavaGuard** 的 MMDS 两列记为 N/A. 该模型是 LLaVA-1.5 架构，真实上下文只有 4096 token，而 MMDS 的对话（含每图 576 token 的视觉输入）远超这个长度：实际只有 49/330 (Q) 与 54/327 (R) 行能被装下，其余被 vLLM 以 400 拒绝。在 15% 覆盖率上算出的 F1 (0.0186 / 0.0000) 是上下文上限的度量，不是模型判断力的度量，因此留空——论文该列为 0.6800 / 0.6972，说明其评测做了截断或不同的输入组装。
- **Qwen3-VL-235B**. 未跑完：它在 ModelScope 上只有 FP8 版（权重 221.3 GiB）。该模型有 64 个注意力头，tensor-parallel 世界大小必须整除 64——\*\*5 卡不是合法分片数 \*\*，而 4 卡  $\times 48 \text{ GiB} = 192 \text{ GiB}$  装不下权重，\*\* 唯一可行配置是单节点 8 卡 \*\*。权重已开始在闲置节点上预下载，一旦凑够 8 张空闲卡即自动以 TP=8 启动（logs/qwen235b.log）。
- 评测口径. 全部基线均使用各自发布的 prompt/模板（非统一模板），但仍属近似——论文只公布了 SingGuard 的模板——故基线行的逐列  $\Delta$  供参考。
- **ShieldGemma-2** 是纯图像分类器，无图的行直接跳过，故其 JailBreakV 一行只覆盖有图的 338 条（JailBreakV 公开图像仅 360 张）。