

表 1: 复现结果与论文表 4 的对比 (F1)。每个模型占两行: 第一行为我们复现的分数, 其下为 $\Delta = \text{复现值} - \text{论文值}$ 。平均列按两侧都有的 8/8 列取平均。

模型	VLGuard	JailBreakV	SPA-VL	MMDS-Q	MMDS-R	VLSBench	MM-Safety	BeaverTails-V	平均
Qwen3-VL-8B	0.6003	0.7593	0.6214	—	—	0.3207	0.5005	0.7273	0.5882
Δ vs 论文	+0.0468	-0.1691	-0.0786	—	—	-0.4377	-0.1401	+0.0766	-0.0611
Qwen3-VL-4B	0.8238	0.8297	0.6824	—	—	0.8758	0.8820	0.5611	0.7758
Δ vs 论文	+0.2536	-0.0909	+0.0319	—	—	+0.1890	+0.2717	-0.1617	+0.1389
LlavaGuard	0.4290	0.4756	—	—	—	—	—	—	0.4523
Δ vs 论文	-0.0713	+0.1566	—	—	—	—	—	—	-0.0417
GuardReasoner-VL-7B	0.8822	0.9005	0.6541	—	—	0.6130	0.6318	0.5149	0.6994
Δ vs 论文	-0.0211	-0.0447	-0.0443	—	—	-0.0176	-0.0380	-0.0271	+0.0510
SingGuard-2B	0.9549	0.9154	0.6960	0.9379	0.9291	0.9889	0.9530	0.8071	0.8978
Δ vs 论文	+0.0158	-0.0351	-0.0822	-0.0318	+0.0331	+0.0286	+0.1121	+0.0024	+0.0054
SingGuard-4B	0.9472	0.9071	0.7005	0.9032	0.9046	0.9712	0.7891	0.8427	0.8707
Δ vs 论文	+0.0176	-0.0623	-0.0755	-0.0573	+0.0317	+0.0179	-0.0714	+0.0090	-0.0238
SingGuard-8B	0.9536	0.9083	0.7089	0.9571	0.8908	0.9551	0.8653	0.8234	0.8828
Δ vs 论文	+0.0025	-0.0645	-0.0795	-0.0280	-0.0055	-0.0117	-0.0159	-0.0081	-0.0263

说明

- **配置**. 使用官方发布的 checkpoint; SingGuard 各行采用论文 Sec. 2.6 中面向高吞吐基准评测的 `thinking_type=fast`, 贪心解码, `max_model_len=32768`。
- **MMDS 口径**. 语料自带官方 `set` 字段 (train 4045 / val 109 / test 330), 我们与论文一致地评测 `test` 划分。若改为在全量语料上分层采样, SingGuard-8B 会掉到 0.7722/0.7209——该列此前的差距源于我们这边的采样错误, 而非协议或权重的差异。
- **SPA-VL 协议**. 官方测试集为 EvalHarm (265) + EvalHelp (265); 其文件名 *并非* 查询安全性标签 (EvalHelp 衡量有用性, 且包含带仇恨标注的图像; EvalHarm 衡量拒答行为)。我们按 `harm→unsafe / help→safe` 映射, 这是与该列论文数值最自治的读法; 其绝对值应视为依赖协议。
- **JailBreakV 覆盖率**. HF 上仅有约 360 张 (共 28,000 张) 图像, 因此我们采样的 1000 行中有 662 行为纯文本。在带图像子集 (该基准的设计形态) 上, SingGuard-8B 的 F1 为 0.9600, 论文为 0.9728。
- **MM-Safety 全为 unsafe**. 该基准由恶意指令构成 (我们采样的每一行 `gold` 均为 `unsafe`), 因此其 F1 退化为攻击集上的加权召回, 对采样到哪些攻击敏感。
- **基线实现保真度**. 每条基线都走其自身发布的 `prompt`/模板, 而非统一模板。由此发现并修复了两处缺陷: LlavaGuard 的模板以 `chat_template.json` 形式发布且 `tokenizer_config` 中没有内联副本, 导致 vLLM 静默改用通用模板, 26% 的样本返回缺失开头键的 JSON 残片; GuardReasoner-VL 的官方接口 (INSTRUCTION 作为 `system message`、`Human user:/AI assistant:` 转录、结论置于 `<result>` 块) 并非常规 `chat` 调用。总体而言基线 `prompt` 仍是近似——论文只公布了 SingGuard 的模板——故其逐列 Δ 仅供参考, 并非精确值。
- **尚缺**. LlamaGuard3-Vision-11B 与 LlamaGuard4-12B 两行 (已排队); LLaVASHield-v1.0-7B 发布的是 LLaVA-NeXT 训练格式 checkpoint (LlavaQwenForCausalLM, 无 `auto_map`), vLLM 0.11 与 `transformers` 均无法直接加载——转换版本正在验证中。
- **Qwen3-VL-235B 未运行**: bf16 (约 470 GB) / FP8 (约 235 GB) 无法在共享的 8×A6000 节点上容纳 (除非使用多卡张量并行)。