

表 1: SingGuard 技术报告表 4 的复现：多模态安全基准结果（unsafe 类 F1）。使用官方发布的 checkpoint，`thinking_type=fast`，贪心解码。本表包含 8/8 列。

模型	VLGuard	JailBreakV	SPA-VL	MMDS-Q	MMDS-R	VLSBench	MM-Safety	BeaverTails-V	平均
Qwen3-VL-8B	0.6003	0.7593	0.6214	—	—	0.3207	0.5005	0.7273	0.5882
Qwen3-VL-4B	0.8238	0.8297	0.6824	—	—	0.8758	0.8820	0.5611	0.7758
LlavaGuard	0.4290	0.4756	—	—	—	—	—	—	0.4523
GuardReasoner-VL-7B	0.8822	0.9005	0.6541	—	—	0.6130	0.6318	0.5149	0.6994
SingGuard-2B	0.9549	0.9154	0.6960	0.9379	0.9291	0.9889	0.9530	0.8071	0.8978
SingGuard-4B	0.9472	0.9071	0.7005	0.9032	0.9046	0.9712	0.7891	0.8427	0.8707
SingGuard-8B	0.9536	0.9083	0.7089	0.9571	0.8908	0.9551	0.8653	0.8234	0.8828

说明

- **配置.** 使用官方发布的 checkpoint；SingGuard 各行采用论文 Sec. 2.6 中面向高吞吐基准评测的 `thinking_type=fast`，贪心解码，`max_model_len=32768`。
- **MMDS 口径.** 语料自带官方 `set` 字段（train 4045 / val 109 / test 330），我们与论文一致地评测 *test* 划分。若改为在全量语料上分层采样，SingGuard-8B 会掉到 0.7722/0.7209——该列此前的差距源于我们这边的采样错误，而非协议或权重的差异。
- **SPA-VL 协议.** 官方测试集为 EvalHarm (265) + EvalHelp (265)；其文件名 *并非* 查询安全性标签（EvalHelp 衡量有用性，且包含带仇恨标注的图像；EvalHarm 衡量拒答行为）。我们按 `harm→unsafe` / `help→safe` 映射，这是与该列论文数值最自治的读法；其绝对值应视为依赖协议。
- **JailBreakV 覆盖率.** HF 上仅有约 360 张（共 28,000 张）图像，因此我们采样的 1000 行中有 662 行为纯文本。在带图像子集（该基准的设计形态）上，SingGuard-8B 的 F1 为 0.9600，论文为 0.9728。
- **MM-Safety 全为 unsafe.** 该基准由恶意指令构成（我们采样的每一行 gold 均为 unsafe），因此其 F1 退化为攻击集上的加权召回，对采样到哪些攻击敏感。
- **基线实现保真度.** 每条基线都走其自身发布的 prompt/模板，而非统一模板。由此发现并修复了两处缺陷：LlavaGuard 的模板以 `chat_template.json` 形式发布且 `tokenizer_config` 中没有内联副本，导致 vLLM 静默改用通用模板，26% 的样本返回缺失开头键的 JSON 残片；GuardReasoner-VL 的官方接口（INSTRUCTION 作为 system message、Human user:/AI assistant: 转录、结论置于 `<result>` 块）并非常规 chat 调用。总体而言基线 prompt 仍是近似——论文只公布了 SingGuard 的模板——故其逐列 Δ 仅供参考，并非精确值。
- **尚缺.** LlamaGuard3-Vision-11B 与 LlamaGuard4-12B 两行(已排队)；LLaVASHield-v1.0-7B 发布的是 LLaVA-NeXT 训练格式 checkpoint (LlavaQwenForCausalLM, 无 `auto_map`)，vLLM 0.11 与 transformers 均无法直接加载——转换版本正在验证中。
- **Qwen3-VL-235B 未运行:** bf16 (约 470 GB) / FP8 (约 235 GB) 无法在共享的 8×A6000 节点上容纳（除非使用多卡张量并行）。