

表 1: SingGuard 技术报告表 4 的复现：多模态安全基准结果（unsafe 类 F1）。使用官方发布的 checkpoint，`thinking_type=fast`，贪心解码。本表包含 8/8 列。

模型	VLGuard	JailBreakV	SPA-VL	MMDS-Q	MMDS-R	VLSBench	MM-Safety	BeaverTails-V	平均
Qwen3-VL-235B	0.6254	0.8688	0.5957	—	—	0.2301	0.4855	0.7620	0.5946
Qwen3-VL-8B	0.6003	0.7593	0.6214	0.5532	0.6567	0.3207	0.5005	0.7273	0.5924
Qwen3-VL-4B	0.8238	0.8297	0.6824	0.7485	0.7051	0.8758	0.8820	0.5611	0.7635
LlavaGuard	0.4288	0.4615	0.3047	—	—	0.4556	0.0931	0.3460	0.3483
SafeGuard-VL	0.6675	0.3806	0.4000	0.3628	0.4153	0.7945	0.5765	0.5052	0.5128
ShieldGemma-2	0.5564	0.3184	0.6499	0.4897	0.1818	0.5359	0.2985	0.5091	0.4425
GuardReasoner-VL-7B	0.8822	0.9005	0.6541	0.4259	0.2914	0.6130	0.6318	0.5149	0.6142
LLaVASHield	0.7816	0.9669	0.6735	0.8667	0.8160	0.9919	0.9974	0.6282	0.8403
SingGuard-2B	0.9549	0.9154	0.6960	0.9379	0.9291	0.9889	0.9530	0.8071	0.8978
SingGuard-4B	0.9472	0.9071	0.7005	0.9032	0.9046	0.9712	0.7891	0.8427	0.8707
SingGuard-8B	0.9536	0.9083	0.7089	0.9571	0.8908	0.9551	0.8653	0.8234	0.8828

说明

- 三列全 **unsafe**，其 **F1** 实为召回率。JailBreakV、VLSBench、MM-Safety 无 safe 样本，故 precision 恒为 1、 $F1 = 2R/(1 + R)$ ——不能与其余列等同解读，对采样到哪些攻击也极敏感。
- **MMDS** 口径（最大修正）。语料自带 `set` 字段（train/val/test = 4045/109/330），我们最初漏了它、在全量上采样（93% 是训练集）。改评 test 后 SingGuard-8B 由 0.7722/0.7209 升到 **0.9571/0.8908**（论文 0.9851/0.8963）。
- 基线必须用各自的官方 **prompt**。用通用提示词会让模型输出错格式而被判错：GuardReasoner-VL（需 system 消息 + `<result>` 块）修复后 VLGuard 0.2973→0.8822；LlavaGuard 用官方策略文本后 26% 的解析失败归零。
- 剩余缺口均已归因。SPA-VL：官方 test 无查询安全性标签，协议存歧义；JailBreakV：公开图像只有 360/28000；LlavaGuard（4096 上下文）与 LLaVASHield 在 MMDS 上卡的是上下文上限，并非模型能力。
- 结论：发布权重可以复现 Table 4。八列平均 2B 0.8978 ($\Delta+0.005$)、8B 0.8828 ($\Delta-0.026$)，逐列 $|\Delta|$ 多数 ≤ 0.03 。
- Qwen3-VL-235B 为 4bit 量化（Q4_K_M），非论文的 bf16/FP8，只能看趋势；其 MMDS-Q 为 API 抽样估计、MMDS-R 未跑。