

表 1: SingGuard 技术报告表 4 的复现：多模态安全基准结果（unsafe 类 F1）。使用官方发布的 checkpoint，`thinking_type=fast`，贪心解码。本表包含 8/8 列。

模型	VLGuard	JailBreakV	SPA-VL	MMDS-Q	MMDS-R	VLSBench	MM-Safety	BeaverTails-V	平均
Qwen3-VL-235B	0.6254	0.8688	0.5957	—	—	0.2301	0.4855	0.7620	0.5946
Qwen3-VL-8B	0.6003	0.7593	0.6214	0.5532	0.6567	0.3207	0.5005	0.7273	0.5924
Qwen3-VL-4B	0.8238	0.8297	0.6824	0.7485	0.7051	0.8758	0.8820	0.5611	0.7635
LlavaGuard	0.4288	0.4615	0.3047	—	—	0.4556	0.0931	0.3460	0.3483
SafeGuard-VL	0.6675	0.3806	0.4000	0.3628	0.4153	0.7945	0.5765	0.5052	0.5128
ShieldGemma-2	0.5564	0.3184	0.6499	0.4897	0.1818	0.5359	0.2985	0.5091	0.4425
GuardReasoner-VL-7B	0.8822	0.9005	0.6541	0.4259	0.2914	0.6130	0.6318	0.5149	0.6142
LLaVaShield	0.7816	0.9669	0.6735	0.8667	0.8160	0.9919	0.9974	0.6282	0.8403
SingGuard-2B	0.9549	0.9154	0.6960	0.9379	0.9291	0.9889	0.9530	0.8071	0.8978
SingGuard-4B	0.9472	0.9071	0.7005	0.9032	0.9046	0.9712	0.7891	0.8427	0.8707
SingGuard-8B	0.9536	0.9083	0.7089	0.9571	0.8908	0.9551	0.8653	0.8234	0.8828

说明

- 基准分组（原文 **Table 4** 说明）。视觉语言越狱（JailBreakV、VLSBench、MM-Safety）、政策驱动的多模态审核（VLGuard、SPA-VL、BeaverTails-V）、MMDS 的查询/响应拆分（MMDS-Q 判用户侧意图、MMDS-R 判助手侧协助，两者独立评分）。
- 评测协议（原文 **4.1**）。全部基准走同一生成式 guard 接口；解析首个 safe/unsafe 判定 token，需归因时取 `<answer>` 内的类别；无法给出判定的输出 按错误计、不重试。query-side 判请求本身是否应拦截，response-side 判回复是否构成有害协助，多模态 response 基准按 (query, image, response) 三元组联合判定。
- 三列越狱类基准（原文 **4.2** 的提醒）。原文指出这三列”会被专门训练于越狱模板的 guard 刷至饱和，单一聚合数值可能掩盖对拒绝模板的过拟合”。本表中 JailBreakV、VLSBench、MM-Safety 采样到的每一行 gold 均为 unsafe，故 precision 恒为 1、 $F1 = 2R/(1 + R)$ ——其数值只反映召回。
- MMDS 口径。语料自带 set 字段 (train/val/test = 4045/109/330)，与原文一致评测 test 划分。八列宏平均：SingGuard-2B 0.8978、4B 0.8707、8B 0.8828（原文 0.8924 / 0.8945 / 0.9092）。
- 其余各列差异的来源。SPA-VL：官方 test 集为 EvalHarm + EvalHelp，本身不含查询安全性标签，映射依赖协议选择；JailBreakV：公开图像仅 360/28000，我们 1000 条中 662 条为纯文本；LlavaGuard 与 LLaVaShield 在 MMDS 上受各自上下文上限（4096 / 32768）限制，超出部分按协议记为错误。
- 基线提示词。原文仅公布 SingGuard 的模板，基线提示词依其各自模型卡组装，故基线行的逐列 Δ 为参考值。
- Qwen3-VL-235B 为 4bit 量化（Q4_K_M），非原文的 bf16/FP8，仅供趋势参考；其 MMDS-Q 为 API 抽样估计、MMDS-R 未跑。